

微信人格聊天系统课程报告

基于微信聊天数据、Qwen2.5-7B-Instruct 与 LoRA 的人格聊天实验

经济学院 2210644 刘沛毓

2026 年 5 月 25 日

摘要

本报告围绕微信人格聊天系统课程项目展开，目标是利用微信私聊数据构建人格化对话数据集，并在 Qwen2.5-7B-Instruct 基座上采用 LoRA 进行监督微调，得到能够模仿特定人物语气、措辞与表达惯性的对话模型。根据当前工作区中可直接核验的实验材料，项目共覆盖 3 类目标人物（老师、同学、亲人），总样本数为 6251 条，其中训练集 5625 条、测试集 626 条。评测部分采用五层指标体系，从文本重合度、语义相似度、风格细节、LLM-as-a-Judge 以及稳定性五个方面对 Base 模型与 LoRA(history) 模型进行对比。总体结果表明，LoRA(history) 在风格相关指标上有稳定提升，尤其体现在 Embedding Cosine、长度相似度、标点习惯和语气词使用上。L4 指标显示三组人物的加权总体胜率为 0.4776，其中某同学组达到 0.6014，说明该组微调已经能够稳定优于基座模型。

1 评测体系

本项目没有只使用 BLEU 之类的单一指标，而是构建了五层评测体系，以便同时观察语义、风格与人格稳定性。具体如表 1 所示。

表 1: 五层评测体系

层级	指标	含义
L1	BLEU4	传统文本重合度，衡量字面匹配程度
L2	Embedding Cosine	语义向量相似度，衡量回复语义贴近程度
L3	KHR / LenSim / PuncSim / ModalSim	关键词命中、句长、标点和语气词等风格细节
L4	Tone / Semantic / Fidelity / Win Rate	使用 LLM-as-a-Judge 对语气、语义、人物贴合度及相对胜率进行打分
L5	AdvDrift / StyleCons	衡量对抗提示下的稳定性与整体风格一致性

为避免展示口径混乱，正文只保留最终汇报中实际使用并参与分析的指标，不再展开未进入最终展示结果的实验性指标。

2 评测效果

2.1 平均结果：Base 与 LoRA(history) 的整体对比

表 2 给出了三位目标人物在 Base 模型与 LoRA(history) 模型上的平均结果。这里的平均是对三组人物结果做简单平均，与课程汇报 PPT 中展示数值一致，并已由本地结果文件重新核算。

表 2: 平均评测结果: Base vs. LoRA(history)

指标	Base	LoRA(history)	指标方向
BLEU4	0.0093	0.0114	越高越好
Embedding Cosine	0.3456	0.4049	越高越好
KHR	0.0113	0.0126	越高越好
Length_Sim	0.2649	0.4670	越高越好
Punctuation_Sim	0.9190	0.9870	越高越好
Modal_Sim	0.8352	0.9392	越高越好
Tone	0.3979	0.6021	越高越好
Semantic	0.4278	0.5722	越高越好
Fidelity	0.4307	0.5693	越高越好
Win Rate	0.5224	0.4776	越高越好
Adversarial_Drift	0.5882	0.5757	越低越好
Style_Consistency	0.7916	0.8397	越高越好

从平均结果可以看到, LoRA(history) 的主要收益集中在风格相关指标上。EmbCos、LenSim、PuncSim、ModalSim, 以及 Tone、Fidelity、StyleCons 都有明显提升, 说明微调后的模型在表达习惯、句子长度、标点使用、语气词和整体人设一致性上更接近目标人物。与此同时, Win Rate 没有同步上升, 这也正是后文需要专门解释的问题。

2.2 分人物结果: 与 PPT 展示口径一致的完整指标

为了与课程汇报 PPT 保持一致, 分人物结果不再把 L4 单独拆出, 而是将 Base 与 LoRA(history) 在同一人物上的展示指标放在同一张表中统一比较。

表 3: 某老师组评测结果: Base vs. LoRA(history)

指标	Base	LoRA(history)
BLEU4	0.0059	0.0137
Embedding Cosine	0.2764	0.3697
KHR	0.0086	0.0114
Length_Sim	0.1928	0.4877
Punctuation_Sim	0.9750	1.0000
Modal_Sim	0.9050	0.9619
Tone	0.5229	0.4771
Semantic	0.5038	0.4962
Fidelity	0.5629	0.4371
Win Rate	0.7143	0.2857
Adversarial_Drift	0.5366	0.6789
Style_Consistency	0.8346	0.8396

表 4: 某同学组评测结果: Base vs. LoRA(history)

指标	Base	LoRA(history)
BLEU4	0.0094	0.0104
Embedding Cosine	0.3718	0.4525
KHR	0.0104	0.0121
Length_Sim	0.2172	0.5185
Punctuation_Sim	0.9499	0.9966
Modal_Sim	0.8458	0.9553
Tone	0.3120	0.6880
Semantic	0.3674	0.6326
Fidelity	0.3378	0.6622
Win Rate	0.3986	0.6014
Adversarial_Drift	0.6335	0.5028
Style_Consistency	0.7682	0.9045

表 5: 某亲人组评测结果: Base vs. LoRA(history)

指标	Base	LoRA(history)
BLEU4	0.0125	0.0101
Embedding Cosine	0.3884	0.3924
KHR	0.0149	0.0142
Length_Sim	0.3846	0.3949
Punctuation_Sim	0.8320	0.9645
Modal_Sim	0.7548	0.9005
Tone	0.4496	0.5504
Semantic	0.4722	0.5278
Fidelity	0.4852	0.5148
Win Rate	0.5913	0.4087
Adversarial_Drift	0.5946	0.5454
Style_Consistency	0.7719	0.7750

从分人物结果看, 某同学组的整体收益最明显, 几乎所有风格相关指标都同步提升, 说明当数据量更大、表达模式更集中时, LoRA(history) 更容易学到稳定的人设特征。某亲人组的提升存在但更有限, 说明这组数据中的风格信号更分散。某老师组则最能体现本项目评测口径的张力: 虽然长度、标点、语气词等风格指标提升明显, 但 Tone、Fidelity 和 Win Rate 反而被 Base 压过, 说明这一组更容易受到裁判偏好与回复长度差异的影响。

2.3 history 消融实验

为了验证历史上下文是否真正有帮助, 项目还在某老师组上比较了 LoRA(no history) 与 LoRA(history)。这部分 no history 结果并未保留独立的 `summary_stats.csv`, 但从本地 `final_eval_report.csv` 逐样本复算出均值, 因此仍然是可复核的本地证据。结果如表 6 所示。

表 6: 某老师组 history 消融实验

指标	LoRA(no history)	LoRA(history)
Embedding Cosine	0.3392	0.3697
Tone	0.3143	0.3476
Fidelity	0.2571	0.2876
Modal_Sim	0.9429	0.9619

这组对照说明，`history` 不是装饰字段，而是人格延续的重要条件。保留上下文后，模型更容易维持目标人物的语气惯性、回复节奏和局部表达风格，因此在人设感上表现得更稳定。

3 结果讨论

3.1 为什么风格增强后 Win Rate 反而下降

Win Rate 本质上依赖大模型裁判对两条回复做整体比较；如果问题表述得过于宽泛，而没有明确要求从语气、风格和人物贴合度出发判断，那么裁判模型就可能把回复是否更完整、是否信息量更大当作主要依据。

在本项目中，Base 模型的回复通常明显更长，也更像通用聊天模型中的标准答案。因此即使 LoRA(history) 在 Tone、Fidelity 等人格相关指标上更接近目标人物，裁判模型仍可能因为 Base 回复更长、更全面而把票投给 Base。换句话说，Win Rate 在这里掺入了回复长度与通用表达偏好的影响，未必完全等价于人格模仿效果本身。

因此，本项目的主要收获仍然是模型说话越来越接近目标人物，而不是在宽泛的整体偏好比较中稳定胜出。这也是为什么在解读人格微调效果时，应当更重视 Tone、Fidelity 以及结合判题口径后的 Win Rate。

综合现有实验结果，可以得出以下结论：

- 基于微信聊天数据构建人格化监督样本，并在 Qwen2.5-7B-Instruct 上进行 LoRA 微调，是一条可行的课程项目路线。
- LoRA(history) 的最大价值在于增强对目标人物风格的贴近能力，而不是提升通用语义问答表现。
- L4 指标显示三组人物加权总体胜率达到 0.4776，其中某同学组达到 0.6014，说明风格微调在部分人物上已经取得了可验证收益。
- history 上下文对人格延续有直接帮助，能够提升语气模仿、人物贴合度和风格一致性。
- 不同人物的数据分布会显著影响微调收益，风格越集中、越稳定的人物，越容易被模型学会。